

Prédiction du Diabète : Une approche préventive

Projet traitement de données

Yassine El Hadiri Florent Accaries Jibril Khay

Polytech Nice-Sophia

Jeudi 4 Juin 2026

Business Goal : Un pré-diagnostic à grande échelle


Quel est notre jeu de données ?

- Une base de données construite sur des **déclarations de santé**.
- Elle croise des **indicateurs cliniques simples** (hypertension, IMC), des **habitudes de vie** (sport, alimentation, tabagisme) et un **profil socio-économique**.

Pourquoi ce jeu de données est-il utile ?

- **Enjeu actuel** : Le dépistage traditionnel repose sur des analyses sanguines (invasives, logistiquement lourdes et coûteuses).
- **Objectif** : Transformer un simple questionnaire en un **premier filtre d'alerte algorithmique**.
- **L'impact** : Identifier de manière précoce et non-invasive les profils à risque pour mieux orienter les ressources médicales.

Corrélation des données avec Diabetes Binary



Aperçu du Dataset :

- **Cible (Target) :**
Diabetes_binary (0 ou 1)
- **21 Features** divisées en :
 - **14 Binaires**
(ex : HighBP, Smoker)
 - **4 Ordinales**
(ex : Age, Income)
 - **3 Continues**
(ex : BMI)

Figure – Corrélation de nos variables avec Diabetes_binary

Feature Engineering : Combinaison de Variables

L'objectif

Agréger des variables binaires simples pour modéliser des **concepts cliniques complexes**.

Features combinées :

- **Mode de Vie** : Activité + Fruits + Légumes.
- **Risque Métab.** : IMC + Tension + Cholestérol.
- **Socio-Éco.** : Éducation + Revenus.

Heatmap finale 3D — Taux de diabète selon BMI_Risk, HighBP et HighChol




Figure – Combinaison des features

Bilan de l'Analyse

- **Validation métier** : Preuve chiffrée de l'effet protecteur d'un mode de vie sain face aux risques métaboliques.
- **Prediction** : Notre régression logistique permet de développer un modèle efficace.
- **Efficacité du dépistage** : Maintien d'un excellent taux de détection (Rappel à 74 %) limitant les faux négatifs.

Pistes d'amélioration

- **Données** : Remplacer les réponses binaires par des variables continues (ex : minutes exactes de sport/semaine).
- **Algorithmes** : Tester des modèles non linéaires (ex : Random Forest) pour viser une meilleure prédiction.