

Prédiction du Diabète : Une approche préventive

Projet traitement de données

Yassine El Hadiri Florent Accaries Jibril Khay

Polytech Nice-Sophia

Jeudi 4 Juin 2026

Business Goal : Un pré-diagnostic à grande échelle


Quel est notre jeu de données ?

- Une base de données construite sur des **déclarations de santé**.
- Elle croise des **indicateurs cliniques simples** (hypertension, IMC), des **habitudes de vie** (sport, alimentation, tabagisme) et un **profil socio-économique**.

Pourquoi ce jeu de données est-il utile ?

- **Enjeu actuel** : Le dépistage traditionnel repose sur des analyses sanguines (invasives, logistiquement lourdes et coûteuses).
- **Objectif** : Transformer un simple questionnaire en un **premier filtre d'alerte algorithmique**.
- **L'impact** : Identifier de manière précoce et non-invasive les profils à risque pour mieux orienter les ressources médicales.

Corrélation des données avec Diabetes Binary



Aperçu du Dataset :

- **Cible (Target) :**
Diabetes_binary (0 ou 1)
- **21 Features** divisées en :
 - **14 Binaires**
(ex : HighBP, Smoker)
 - **4 Ordinales**
(ex : Age, Income)
 - **3 Continues**
(ex : BMI)

Figure – Corrélation de nos variables avec Diabetes_binary

Feature Engineering : Combinaison de Variables

L'objectif

Agréger des variables binaires simples pour modéliser des **concepts cliniques complexes**.

Features combinées :

- **Mode de Vie** : Activité + Fruits + Légumes.
- **Risque Métab.** : IMC + Tension + Cholestérol.
- **Socio-Éco.** : Éducation + Revenus.

Heatmap finale 3D — Taux de diabète selon BMI_Risk, HighBP et HighChol




Figure – Combinaison des features

Modélisation : Régression Logistique & Défi du Réel

Pourquoi ce modèle ?

Classification binaire idéale, robuste et **interprétable** (poids des variables pour la prévention).

1. Échantillon Équilibré (50/50) – Validation ($AUC = 0,803$)

- **Sains (0)** : Précision 0,74 | Rappel 0,71
- **Diabétiques (1)** : Précision 0,72 | **Rappel 0,74** (7 843 VP)

2. Dataset Complet Réel – Le défi du déséquilibre (85/15)

- **Sains (0)** : Précision 0,94 | Rappel 0,72
- **Diabétiques (1)** : Précision 0,32 | **Rappel 0,74** (26 136 VP)

1. RÉSULTATS SUR DATASET ÉQUILIBRÉ (TEST SET 50/50)				
	precision	recall	f1-score	support
Sain (0)	0.74	0.71	0.72	10530
Diabétique (1)	0.72	0.74	0.73	10529
accuracy			0.73	21059
macro avg	0.73	0.73	0.73	21059
weighted avg	0.73	0.73	0.73	21059
ROC AUC : 0.803				

2. RÉSULTATS SUR DATASET COMPLET NON ÉQUILIBRÉ (RÉALITÉ)				
	precision	recall	f1-score	support
Sain (0)	0.94	0.72	0.81	194377
Diabétique (1)	0.32	0.74	0.45	35097
accuracy			0.72	229474
macro avg	0.63	0.73	0.63	229474
weighted avg	0.84	0.72	0.76	229474
ROC AUC : 0.804				




Figure – Rapports et matrices (Équilibré vs Réel)

Bilan de l'Analyse

- **Validation métier** : Preuve chiffrée de l'effet protecteur d'un mode de vie sain face aux risques métaboliques.
- **Prediction** : Notre régression logistique permet de développer un modèle efficace.
- **Efficacité du dépistage** : Maintien d'un excellent taux de détection (Rappel à 74 %) limitant les faux négatifs.

Pistes d'amélioration

- **Données** : Remplacer les réponses binaires par des variables continues (ex : minutes exactes de sport/semaine).
- **Algorithmes** : Tester des modèles non linéaires (ex : Random Forest) pour viser une meilleure prédiction.